

Aimers

임재민 aimers project 정리

LG Aimers 예선 (KBO 제구 예측)

기간: 8/5~9/1

최종 1158. 69등/1090팀 (상위 6%)


과정

내용	점수	시도해본 것들
Catboost+histGB ensemble버전	984	Catboost, XGB 등 tree기반 부스팅 모델들
팀원 TabM 내용 수령	1046	DeepLearning 기반 모델이 해당 데이터셋에 관하여 강력한 성능을 내는 것을 확인후, FC layer만으로 모델 설계 해보고, flatMLP, ResNet 등 다양한 모델들 실험해보고 있는 중, 팀원(지찬)의 TabM 성능이 좋음을 듣고 실험해 봄.
cosine scheduler 수정	1057	기존 TabM 코드에서 epoch가 1만에 거의 수렴 해버리는 현상이 일어남. epoch를 2로 학습시키는데 1만에 수렴되서 나머지 학습이 버려지는 현상 발생. 이에 따라서 epoch 10까지 늘려서 효과 더보려고 했으나 오히려 리더보드 점수는 감소함. → 원인분석: 학습을 길게 할수록 분포가 19~24에 맞춰지는데 epoch를 늘려 학습하는 게 25년 예측에는 맞지 않았던것으로 판단함.
코드간 feature 차이 수정	1069	투-타 플래툰 피쳐를 만드는 과정에서 as-of의 그 직전 행만 보는게 아니라 19~24를 전부다 보게 만드는 실수를 함. 이렇게 되면 학습하려고 하는 정답이 그룹 평균에 들어가버려서 누출됨.
Temperature Scaling 도입	1076	loss 바꾸려고 찾는 과정에서 앙상블 단계에 logit을 평균내면서 사라지는 모델별 확신 정도를 돌려주는 방법을 알게됨. temperature sweep돌려서 최적 찾아 도입했음.
catboost에 피쳐 추가	1083	'이 투수가 이 상황에 얼마나 잘했나?'를 물어보는 피쳐를 추가함.

		pc_c12(투수x카운트12가지), pc_cmh(투수x(타자플래툰x카운트12가지))
DIN도입	1089	아키텍처쪽 고민을 하는중에 피쳐간 상관관계를 잘 이해하는 모델을 잘 찾아봄. DIN, DCNv2, SENet, BST 등 모두 실험했고, DIN이 validation에서 살아남고 TabM과 상관계수가 낮아 앙상블 멤버로 도입했음. (투수의 과거 상태 시퀀스에 현재 상황으로 attention)
Multistate도입	1129	예측 자체가 binary함이 이 task에 가장 큰 문제라고 생각해서 기존에 시도했다 실패했던 success/fail을 자세하게 나눠보았고, 이게 성공하여 큰 상승을 이룸. asof_pitcher_success_rate , asof_pitcher_reverse_rate , asof_pitcher_middle_rate , asof_pitcher_ball_rate , asof_pitcher_strike_rate 모델이 binary한 예측이 아닌 (성공/의도반대/가운데몰림/실패-볼/실패-스트라이크/노이즈) 이 6가지를 학습하게 되어서 훨씬 더 구체적인 신호를 뽑고, 표적이 여러개 생기니 과적합 위험도 줄어 점수가 많이 올랐다고 분석함. 방법: as-of를 통해서 예를 들어 asof_n이 1 늘었는데 asof_reverse_rate가 올랐으면 그 투구를 reverse로 학습.
pcnt 추가 (pitcher x count 상대효과 보정)	1133	이 투수가 어떤 상황에서 자기 평균보다 얼마나 못던졌나, 잘던졌나를 집어넣어서 추론과정에 넣으면 좋겠다라는 생각을 하여 집어넣어보았더니, 특정 볼카운트와 평균을 통해 나온 값을 넣은 곳에서 양수값이 나와서 도입했음.
catboost에 팀원 피쳐 추가	1137	팀원(준혁)이 보내준 플래툰별 피쳐와 최근 폼 피쳐를 추가하였음
Team 13의 체제 전환 확인, 도입	1156	1등팀의 공개 질문에서 힌트를 얻어 13팀 관여행을 파봤더니 2023년 5월부터 성공률이 리그 대비 +7pp 계단 상승한 체제 전환이 확인되었고, 이를 지시자 피쳐로 넣는 방식은 as-of 이력 피쳐가 이미 흡수하고 있어서 검증에서 -24.5로 죽었으나, 대신 우리 모델이 13팀 행에 남긴 잔차를 상수 보정으로 걷는 방향으로 틀어 하향 (-0.08)을 걸었다가 -45로 실패한 뒤 그 낙폭

		을 역산해 실제로는 +2.1pp 과소예측임을 알아내고 부호를 뒤집어 13투 +0.08 / 13타 +0.06을 걸어 +19를 얻었음.
pstr 제거 (pitcher x strike)	1158	최종 점수상승을 원하는 과정에서 추가하기 보단 덜어내보자는 생각이 들어 적용했으나 이 피쳐 제거만 효과가 있었음.\

최종 아키텍처



아쉬웠던 점

1. 팀원 전부다 validation 내용을 계속 집중했는데 결국엔 valdiation 매핑을 못함. 24년 이 결국엔 제일 비슷하다는 결론이 나오긴 했으나, 초반에 이걸 알고있었으면 쓸데없는 걸 내서 제출 수 소진하는게 아니라 제출 여러번 해보면서 리더보드와 가장 맞는 validation set을 팀적으로 만드는데 제일 중요했을 것으로 보임.
2. Multistate에 관한 내용을 계속 인지도 하고 있었고, binary한 예측이 아닌 여러가지를 예측하도록 해보는게 좋았을텐데, 이걸 좀만 더 빨리 시도해보지 못한게 아쉬움.

3. Abs와 team13 단절 등 이런 큰 변화가 있는 곳에서도 신호가 나온다는걸 알고있었는데도 이걸 좀더 직접 찾아보고 해봤으면 좋았을 것 같음.
4. trackman 관련이 안되는걸 알았으면 팀원끼리 빠르게 분담해서 맡기고 맡지 않은사람들은 조금 더 모델쪽에 집중했어야 했던 것 같음.

논문 읽고 정리한 내용

DIN

더 많은 유저의 과거 행동 정보와 같은 다양한 feature를 모델에 사용하고 싶다는 아이디어에서 출발한 것이다. (추천시스템 관련 모델)


기존 예측의 표준은 단순히 Embedding단계후 MLP를 통과시키는 구조였음.

과거 행동을 embedding해서 pooling으로 고정 길이 vector로 압축 후에 이를 MLP에 넣었음.

이 구조의 문제점은 결국엔 이 사용자 vector가 뭘 평가하든 항상 똑같이 나온다는 것임. 사용자의 관심사는 다양한데 특정 광고를 평가할 땐 그중 일부만 관련이 있음. 기존 방식의 고정 벡터는 이 선택적 관련성을 표현할 수 없고, 표현력을 늘리려면 벡터 차원을 키워야 하는데 그러면 과적합함.

그래서 이 논문에서는 후보에 따라 사용자 표현이 달라지게 만들.

중요한 부분: 원 논문은 이 가중치에 softmax 정규화를 일부러 안 함. 정규화하면 합이 1로 고정돼서 "관련 행동이 많은 사용자"와 "적은 사용자"가 구분되지 않기 때문이었음. 관심의 강도를 벡터 크기로 남기려는 의도.




논문 적용 방식 : 기존 feature가 이 논문의 문제상황인 고정된 vector 느낌이었음. (as-of feature들) 또한

관련성들이 전부 상황에 따라 발생하는 야구의 특성이 상당히 유사해보였음 (예를 들어 3-0 과 3-1은 다른 상황이지만 임베딩 공간에서는 가깝게 학습됨)

하지만, 이 task에서는 sequence가 상대적으로 기존 논문에서 제시한것보다 훨씬 짧았기 때문에 softmax 정규화를 할수밖에 없었음.

Temperature Scaling 내용



모델의 정확도는 계속 올라가는데 그 모델이 내놓는 확률값 자체를 믿을 수 있느냐는 별개 문제라는 문제의식에서 출발한 것임. (분류 모델 확률 보정)

기존에는 신경망이 내놓은 softmax 출력을 그대로 확률로 썼음.

그런데 측정해보니 1998년 LeNet은 "90% 확신"이라 한 예측이 실제로 90% 맞았는데, 2016년 ResNet은 같은 90% 확신 예측이 70%밖에 안 맞았음. 정확도는 올라갔는데 확률의 신뢰성은 오히려 나빠진 것임.

원인은 용량이 커질수록, BatchNorm을 쓸수록, weight decay가 약할수록 심해졌음. 기전은 0/1 오차가 이미 평평해진 뒤에도 학습이 NLL을 계속 줄이는데 그 방법이 "더 자신 있게 말하기"밖에 없어서 과신으로 수렴하는 것임.

그래서 이 논문에서는 로짓을 softmax에 넣기 전에 스칼라 하나로 나눠서 확신도만 교정함.
 $p = \text{softmax}(z/T)$, T는 검증셋에서 NLL 최소화로 하나만 적합.

중요한 부분: 단조 변환이라 argmax가 안 바뀜. 즉 정확도나 AUC는 그대로이고 확률값만 교정됨. 그리고 논문이 같이 비교한 파라미터 많은 방법들(isotonic regression, matrix/vector scaling)보다 이 가장 단순한 1-파라미터 방식이 제일 잘 작동했음. 복잡한 방법들은 검증셋에 과적합했기 때문임.

논문 적용 방식: 우리 채점식이 Brier라서 이게 그대로 점수였음. Brier는 신뢰도 - 판별력 + 불확실성으로 분해되는데, 온도는 순위를 안 바꾸니까 판별력은 건드리지 않고 신뢰도 항만 직접 줄임. AUC 대회였으면 아무 효과 없었을 장치가 여기서는 공짜 점수가 되는 구조였음. 다만 방향이 논문과 반대였는데, 우리 시스템은 과신이 아니라 **과소확신**이었음. 4계열 확률 평균 + 멀티시드 평균 + as-of 피처의 베이지 수축 + 신호가 0.93%뿐이라 대부분 행이 0.5 근처에 있는 것까지 겹쳐서 확신이 깎여 있었기 때문임. 그래서 $T < 1$ (날카롭게)이 필요했고, 코드에는 역온도 형태로 $\sigma(1.04 \cdot \text{logit}(p) - 0.007)$ 로 넣었음. shift는 수준(평균), T는 퍼짐(분산)을 담당해서 역할이 직교함.

우리가 다르게 한 것: 논문은 검증셋에서 T를 적합하라고 하는데 우리는 그게 안 통했음. 관문(홀드아웃)이 T의 가치를 17배 과소평가했고 마지막엔 방향까지 반대로 가리켰음. 최적 온도가 "그 모델이 얼마나 평균화·수축돼 있는가"의 함수인데 폴드 모델과 배치 모델의 평균화 정도가 다르고 연도별 라벨 분포도 다르기 때문임. 그래서 리더보드 자체를 검증셋으로 써서 확정했음(넣고 빼는 2회 제출로 ± 7 확인).